❖ Capítulo 10 ❖

Estableciendo los límites del Trabajo-en-Progreso

Como se discutió en el capítulo2, una de las cinco propiedades fundamentales del Método Kanban es que el trabajo en progreso está limitado. Por ende, es correcto decir que una de las decisiones más importantes que usted tomará al introducir Kanban es escoger los límites del trabajo-en-progreso a través del flujo de trabajo.

El capítulo 15 aconseja que los límites del trabajo-en-progreso sean acordados por consenso con las partes interesadas de los niveles anteriores y posteriores de la organización y con la alta dirección. Es cierto que los límites pueden ser declarados unilateralmente; sin embargo, da poder ganar consenso y obtener un compromiso de parte de las partes interesadas exteriores con respecto a la política del límite del

tiene poder. Cuando su equipo y el proceso estén bajo estrés usted puede regresar al convenio colaborativo alrededor del cual hay consenso. Usted puede redirigir la discusión hacia una redefinición del proceso en lugar de acordar el doblar, estirar, o de alguna otra forma usar mal el sistema que se tiene diseñado e implementado. Construir un consenso es una manera de mantener la disciplina del límite del WIP y evitar tener que anular o abandonar el límite.

Límites para las tareas de trabajo

Con el equipo de XIT en Microsoft, Dragos Dimitriu decidió que los desarrolladores y ingenieros de pruebas deberían trabajar en un solo

ítem a la vez. No habría multitareas. Esto fue declarado unilateralmente, pero afortunadamente esta elección no fue problemática para ninguna de las partes interesadas. Esto se alineaba con prácticas de trabajo actuales y el método de Proceso de Software Personal (PSP) que el equipo ya utilizaba. La organización era lo suficientemente madura para mantener disciplina y seguir el proceso que se había acordado. Tal vez recuerde que al inicio del caso de estudio, en el otoño de 2004, había tres desarrolladoresy tres ingenieros de pruebas en el equipo. Por ende, el límite de WIP para cada uno de ellos, desarrollo y pruebas, era de tres.

En Corbis en 2006 tomamos una decisión similar con la iniciativa de ingeniería sustentable; que los analistas, desarrolladores y ingenieros de pruebas trabajarían en tan solo un ítem de trabajo a la vez valorado por el cliente. Con nuevos proyectos grandes tendíamos a tomar decisiones diferentes. Había más trabajo colaborativo en esos proyectos. Era común que equipos de dos o tres personas trabajaran reuniones en un mismo ítem. Debido a que esos ítems podían llegar a bloquearse o retrasarse, especulamos que tendría sentido permitir algún grado de cambio de tareas y algún paralelismo adicional; por lo que el límite de WIP fue establecido para inferir dos o tres personas por ítem y permitir algún sobreflujo. Por ejemplo, si teníamos diez personas y anticipamos dos personas por ítem, el límite de WIP podría ser cinco más algunos más para mitigar el impacto de un bloqueo. Tal vez ocho (cinco más tres) sería el límite correcto para tales circunstancias.

Se ha hecho alguna investigación y observación empírica para sugerir que dos ítems en progreso por trabajador de conocimiento son óptimos. Este resultado es frecuentemente referido para justificar multitareas. Sin embargo, yo creo que esta investigación tiende a reflejar la realidad de trabajo en las organizaciones observadas. Hay muchos impedimentos y razones para que el trabajo se retrase. La investigación no reporta la madurez organizacional de las empresas estudiadas y tampoco correlaciona los datos con ninguna de los factores externos ocurrentes (variaciones de causa asignable, discutidas en el capítulo 19) . Por lo tanto, el resultado puede ser una consecuencia de los ambientes estudiados y no un número ideal en realidad. Sin embargo, usted puede encontrar resistencia a la noción de que un ítem por persona, par, o equipo pequeño es la elección adecuada. Se puede argumentar que tal política es demasiado restrictiva. En ese caso, establecer un límite de WIP de dos ítems por persona, par, o equipo es razonable. Puede que hasta existan casos donde un límite de tres por persona, par, o equipo es aceptable.

No hay una fórmula mágica para la elección. Es importante recordar que el número puede ser ajustado empíricamente. Usted puede seleccionar un número y observar si funciona bien o no. Si no, ajústelo hacia arriba o hacia abajo.

Límites para las Colas

Cuando trabajo es completado y está esperando a ser tomado por el siguiente estado en su flujo de trabajo, se dice que esta "en cola". ¿Que tan grandes deben ser estas colas? Lo más pequeño posible. El límite de WIP para una cola a menudo se agrupa con su paso precedente de trabajo. Por ejemplo, las colas de Desarrollo (*Development*) y de Desarrollo Completado (*Development Done*) están agrupadas, como se muestra en la figura 10.1. Si una política estricta sobre el WIP del trabajo de tareas fue establecida, tal como estrictamente un ítem por persona, par, o equipo pequeño, será necesario tener alguna cola para absorber la variación y mantener el flujo. Si, una vez en operación, su sistema kanban sufre de comportamiento de paro-e-inicio que hace que los trabajadores estén ociosos debido a la variabilidad en la longitud de tiempo que toma completar las tareas, puede que necesite incrementar el tamaño de las colas. Sin embargo, si usted ya hizo la elección de tener, por ejemplo, dos elementos en progreso por persona, par, o equipo pequeño, usted ya tiene buffer para la variabilidad, por lo que el tamaño de la cola puede ser efectivamente cero. Simplemente agrupe la columna del trabajo de tareas de la cola de completado reuniones.

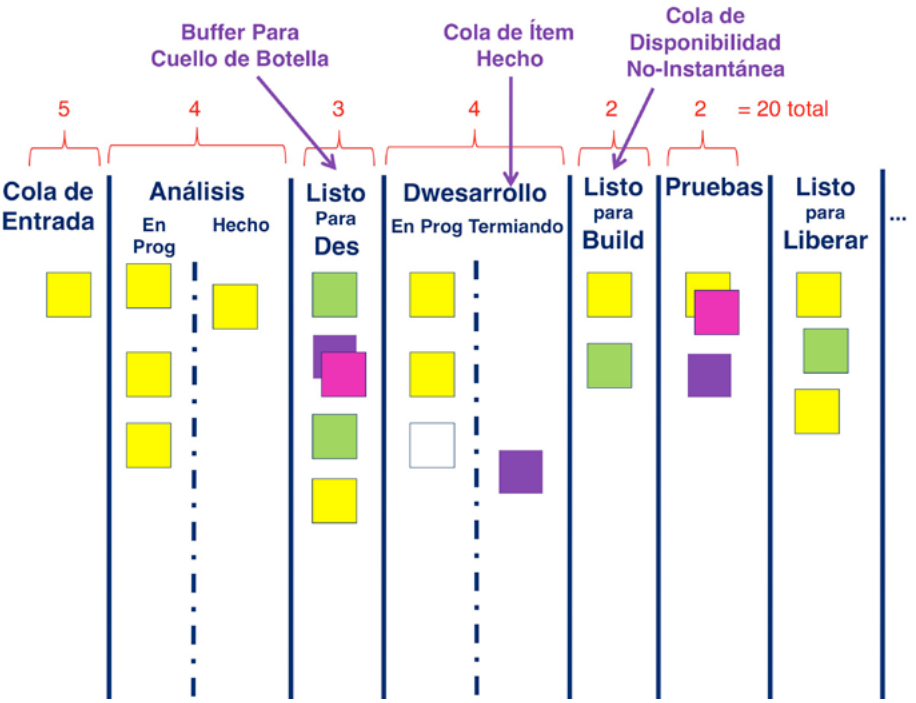


Figura 10.1 Pared de tarjetas mostrando diferentes tipos de colas y un buffer

Buffers de cuellos de botella

El cuello de botella en su flujo de trabajopuede requerir un buffer frente a él, como se muestra en la Figura 10.1. Este es un mecanismo habitual de explotación de cuello de botella. Nuevamente, usted desea que sea lo más pequeño posible.Los buffers y colas agregan trabajo-en-progreso a su sistema y su efecto el alargamiento del tiempo de entrega. Sin embargo, los buffers y colas suavizan el flujo y aumentan el rendimiento, por lo que más trabajo es entregado mediante un sistema kanban. Los buffers también aseguran que la gente continúa trabajando y proporcionan mayor utilización. Necesita haber equilibrio y los buffers ayudan a mantenerlo. En muchas instancias usted busca agilidad de negocio mediante tempos de entrega más cortos y mayor calidad parcialmente por medio del menor monto de trabajo-en-progreso. Sin embargo, no sacrifique la previsibilidad con el fin de lograr agilidad o calidad. Si el tamaño de las colas y los buffers son demasiado pequeño y su sistema sufre de mucho comportamiento de paro-e-inicio debido a la variabilidad, los tiempos de entrega serán impredecibles, con un amplio grado de variabilidad. La clave para escoger un límite de WIP para un buffer es que debe ser lo suficientemente grande para asegurar un flujo suave en el sistema y evitar tiempo de ocio en el cuello de botella. Más detalle sobre el tamaño del buffer y como diseñar buffers tanto para cuellos de botella de capacidad restringida y disponibilidad no instantánea se discute en el capítulo 16.

Tamaño de la cola de entrada

El tamaño de la cola de entrada puede ser determinado directamente de la cadencia de priorización, o tasa de producción, en el sistema. Por ejemplo, si un equipo está produciendo a una tasa media de cinco ítems de trabajo hecho por semana (con un rango habitual de cuatro a siete ítems por semana) y la cadencia de aprovisionamiento de la cola es semanal, el tamaño de la cola debería ser de siete. De nuevo, esto puede ser ajustado empíricamente. Si corre su sistema por varios meses y la cola nunca está completamente agotada antes de la siguiente reunión de priorización, probablemente es muy larga por lo que debe reducirla por uno y observar los resultados. Repita este proceso hasta que tenga una reunión de priorización en la que les está preguntando a los representantes de negocio que surtan la cola completa.

Si, por otro lado, usted tiene una reunión semanal de priorización en un lunes y la cola se agotó el jueves por la tarde—y algunos de los miembros del equipo estuvieron ociosos como resultado de ello—la cola es muy pequeña. Incremente el tamaño de la cola por uno y obsérvelo por varias semanas.

El tamaño de la cola y el buffer deberían ser ajustados empíricamente como sea requerido. Por ello, no se preocupe por la decisión de establecer un límite de WIP. No se demore en desplegar de su sistema kanban porque no puede concordar en los números perfectos

para limitar el WIP. ¡Elija algo! Elija progresar con información imperfecta para entonces observar y ajustar. Kanban es un proceso empírico.

¿De qué tamaño debe ser la cola de entrada si usted está utilizando priorización bajo demanda? Usted recordará que el equipo de XIT en el capítulo 4 tenía una cola de entrada de cinco ítems. Esto estaba diseñado para ser lo suficientemente grande para absorber el rendimiento de una semana. Estaba basado en la asunción de que la reunión de priorización sucedía semanalmente. Sin embargo, los directores de producto decidieron rápidamente que la reunión era innecesaria y que hacer decisiones basadas en eventos cuando un espacio en la cola se hacia disponible era aceptable. Una vez que esto sucedió debí haber aconsejado a Dragos que redujera la entrada de cinco a uno. El no haberlo hecho es un reflejo de mi falta de experiencia en ese entonces. El sistema había cambiado. Las asunciones bajo las cuales había sido diseñado habían cambiado. La política sobre el tamaño de la cola de entrada estaba basada en esas asunciones y debió haber sido revisada. Si hubiésemos hecho eso, la mejora de los tiempos de entrega habría sido aún más impresionante.

Cuando el XIT cambió a priorización bajo demanda normalmente les lleva dos horas para aprovisionar un espacio vacío en la cola. Habría sido aceptable asumir que el tiempo más largo para aprovisionar la cola habría sido de cuatro horas. Sin embargo, los desarrolladores no estaban co-localizados con los directores de producto. Los tomadores de decisión sobre la priorización estaban en Redmond, Washington,y los desarrolladores estaban en Hyderabad, India. Cada uno de ellos estaba en turno trabajando (oficialmente) días de ocho horas en el lado opuesto del reloj. Por lo que es probable que hubiese situaciones en las que cuando en la India llegaran a trabajar en la mañana, terminaran una tarea y necesitaran que la cola fuera resurtida, pero los directores de producto estaban obviamente dormidos en cama. Dado este problema de disponibilidad no inmediata, probablemente deberíamos de haber permitido 16 horas para aprovisionar un solo ítem en la cola bajo situaciones extremas. Recuerde que los desarrolladores eran el cuello de botella en este flujo de trabajo. Con el fin de maximizar rendimiento, nunca queremos que los desarrolladores estén ociosos. Por lo que necesitamos ser conservadores; 16 horas es conservativo cuando la decisión promedio de resurtido de la cola es de tan solo dos horas. Entonces, ¿cuál sería el rendimiento en un periodo promedio de 16 horas? En el rendimiento pico el equipo lograba 56 ítems en un trimestre. Eso es menos de cinco por semana. Por lo que en un periodo de 16 horas es poco probable que completen un solo ítem, es decir, un cola de tamaño uno es perfectamente aceptable. La carencia total de cola es inaceptable. Aún hay probabilidad de que el equipo sufra tiempo de ocio cuando terminen un ítem durante el lapso de 16 horas cuando los directores de producto no estén disponibles para aprovisionar la cola.

Secciones ilimitadas de flujo de trabajo

En la solución de sistema-de-arrastre de la Teoría de Restricciones para problemas de flujo, conocida como Drum-Buffer-Rope, todas las estaciones de trabajo en los niveles posteriores al cuello de botella tienen WIP ilimitado. Este diseño está basado en la asunción de que tienen una capacidad de mayor rendimiento que el cuello de botella y tienen capacidad de holgura que resulta en tiempo de ocio. Como resultado no hay necesidad de un límite de WIP. Esto está ilustrado en la Figura 10.2(a) basada en la metáfora usada en *The Goal* de Goldrat y muestra a un patrulla de scouts excursionando en una fila. La cuerda está atada entre el scout líder y el más lento (el cuarto en la línea), quien es el cuello de botella en el rendimiento (la tasa en la cual la patrulla cubre terreno). Se necesita tan solo una cuerda pues los scouts detrás del más lento nunca se van a retrasar porque pueden caminar más rápido que el cuarto en la línea, quién restringe el paso de la patrulla completa.

Figura 10.2 Hombres de palillo ilustrando cuatro diseños de sistemas de arrastre de WIP limitado

Con un sistema kanban, la mayoría o todas las estaciones en el flujo de trabajo tienen límites de WIP. Esta es una ventaja potencial porque los impedimentos causados por variabilidad no anticipada o esperada puede hacer que un paso en niveles altos del proceso se convierta en un cuello de botella temporal. El límite de WIP local con el sistema kanban detendrá la línea rápidamente, evitando que el sistema se obstruya y se sobrecargue. Cuando el impedimento es eliminado el sistema reinicia con gracia. La limitación de WIP estilo Kanban se ilustra en la figura 10.2(d), la cual muestra como los scouts estarán encordados juntos si usan un estilo de kanban. Es este caso cada scout está encordado al siguiente de la fila. Cinco cuerdas son requeridas para controlar el paso de la patrulla entera de seis scouts.

En algunos casos, puede ser aceptable que un sistema kanban tenga pasos ilimitados de nivel posterior del proceso.En el ejemplo del XIT en Microsoft se asumió que la base de usuario disponible para efectuar pruebas de aceptación era efectivamente infinita y en esencia disponible instantáneamente, por ello no había necesidad de limitar el WIP en las pruebas de aceptación de usuario. En Corbis, la cola de listo-para-entrega era ilimitada. Esto se basaba en la asunción de que el lote de trabajo listo-para-entrega nunca se haría excesivo dada la cadencia acordada de entregas cada dos semanas. Si, por el otro lado, hubiera sido posible que el monto de material listo-para-entrega se hiciera excesivo, habría incrementado la complejidad de la entrega, resultando en que el esfuerzo de coordinación y los costos de transacción de la entrega no fueran no económicos. Habría sido necesario limitar el WIP en la cola de listo-para-entrega. Sin embargo, ese nunca fue el caso en Corbis, por lo que el estado de listo-para-entrega se mantuvo sin restricción.

No estrese a su organización

Escoger límites de WIP demasiado ajustados puede poner estrés excesivo en su organización al principio. Organizaciones con poca madurez con capacidades pobres tendrán más impedimentos. Por ello, organizaciones de baja madurez y con poca capacidad se darán cuenta que la introducir un sistema kanban genera mucha inconveniencia si los límites de WIP son muy bajos. Si hay muchos impedimentos, representados con muchos tickets rosa a lo largo de la pared de tarjetas, límites de WIP demasiado ajustados significarán que todo llegará a un paro y mucha gente estará ociosa. Mientras que el tiempo de ocio tiende a enfocar la atención y acelerar los esfuerzos para resolver problemas y eliminar impedimentos, puede ser demasiado doloroso para una organización con poca madurez. La alta dirección pueden irritarse al observar a demasiada gente ociosa cobrando sus salarios.

Al introducir el cambio, usted necesita serconciente del efecto de la curva "J". Idealmente, cada cambio produce una pequeña "j" donde cualquier impacto en el rendimiento es superficial, el sistema se recupera rápidamente y muestra mejora. Si usted define los límites de WIP demasiado apretados sufrirá el efecto de una curva "J" demasiado pronunciada y larga, lo cual puede generar efectos indeseables: Kanban expone todos los problemas en la organización, pero puede terminar siendo acusada por hacer todo peor y será visto como parte del problema en lugar de como la solución. Actúe con cautela. Con organizaciones más capaces y maduras que sufren menores problemas inesperados (variaciones de causa asignable) usted puede ser más agresivo con sus políticas de límite de WIP. En organizaciones más caóticas es mejor introducir límites más holgados inicialmente, con mayor WIP y con la intención de reducirlos más adelante.

No establecer un límite de WIP es un error

Aunque le advierto que no sea agresivo al establecer los límites del WIP inicial, me he convencido que no establecer los límites de WIP es un error.

Algunos de los primeros en adoptar Kanban, como Yahoo!, optaron por no establecer límites de WIP porque asumían que sus equipos eran demasiado caóticos para sobrellevar el dolor que puede introducir. La esperanza era que estas organizaciones maduran a través de los elementos visuales de control de Kanban y que los límites de WIP podrían introducirse más tarde. Esto resultó ser problemático, sin embargo y varios equipos abandonaron Kanban sin ver grandes mejoras, mientras que otros fueron disueltos en reorganizaciones corporativas o por cancelaciones de proyectos, negándonos dar datos adicionales. En Corbis, varios equipos en grandes proyectos usaban Kanban con límites de WIP muy holgados en la funcionalidad de alto nivel refinada conforme se avanzaba. Los resultados fueron mixtos en cierta medida.

Me he convencido de que la tensión creada por la imposición de un límite de WIP a través de la cadena de valor es tensión positiva. La tensión positiva fuerza discusión sobre las disfunciones y problemas de la organización. Las disfunciones generan impedimentos en el flujo y resultan en productividad, tiempo de entrega y calidad subóptimas. La discusión y colaboración provocada por la tensión positiva de un límite de WIP es saludable. Es el mecanismo que permite el surgimiento de una cultura de mejora continua. Sin límites de WIP el progreso en la mejora del proceso es lento. Los equipos que han impuesto límites de WIP desde el principio han reportado crecimiento acelerado en su capacidad y madurez organizacional y han entregado resultados de negocio superiores con entregasprevisibles frecuentes de software de alta calidad. En comparación, los equipos que han aplazado la introducción de límites de WIP han luchado en general y mostrado mejoras limitadas.

Asignación de la capacidad

Una vez que establecemos los límites de WIP para el flujo a través del sistema, podemos considerar la asignación de la capacidad por tipo de ítem de trabajo o clase de servicio.

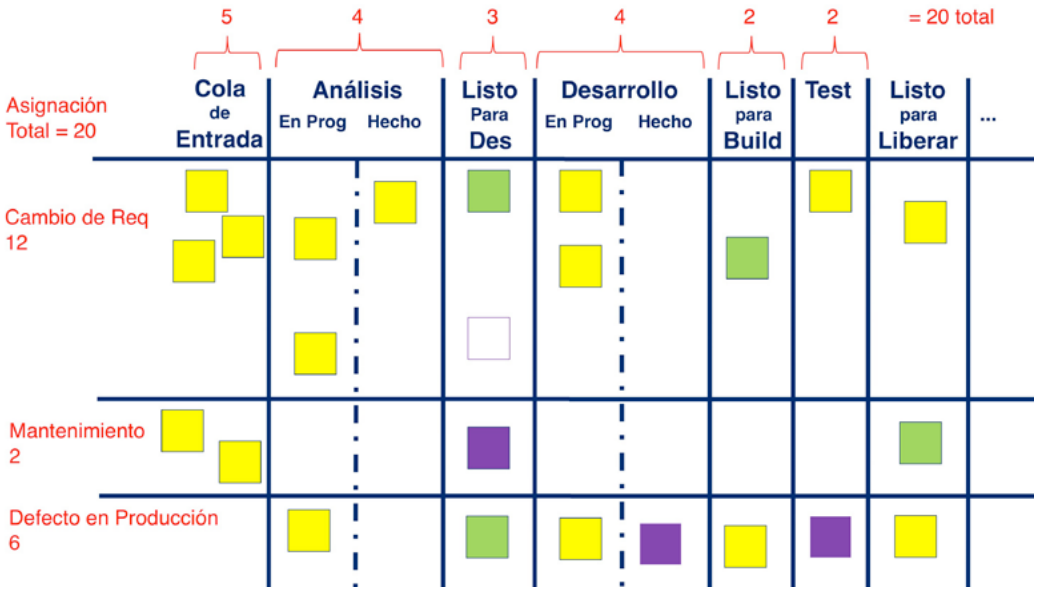


Figura 10.3 Pared de tarjetas mostrando carriles de nado para cada tipo de ítem de trabajo con límites de WIP explícitos para cada carril

La Figura 10.3 muestra el diseño de la pared de tarjetas del capítulo 6 con límites de WIP a través de columnas totalizando 20 tarjetas. La capacidad es asignada a través de los tipos de ítem de trabajo, es decir60 por ciento para solicitudes de cambio, 10% para ítems

de mantenimiento y 30% para cambios de texto en producción. Eso equivale a un límite de WIP por carril de nado de 12 para solicitudes de cambio, 2 para mantenimiento y 6 para cambios de texto en producción.

La asignación de capacidad nos permite garantizar servicio para cada tipo de trabajo recibido por el sistema kanban. La asignación debe hacerse generalmente en respuesta a una demanda comparativa observada para cada tipo de trabajo. Por ende, es importante completar un análisis de demanda para facilitar una asignación razonable de límites de WIP en los carriles de nado para cada tipo de trabajo.

Para llevar

- Los límites WIP deben ser acordados a través de consenso con las partes interesadas de los niveles anteriores y posteriores del proceso y con la alta dirección funcional.
- La declaración unilateral de límites de WIP es posible pero pueden ser difíciles de defender más tarde, cuando los sistemas están bajo estrés.
- Los límites de WIP para tareas de trabajo deben establecerse como un numero promedio de ítems por persona, par de desarrollo, o equipo colaborativo pequeño.
- Normalmente , el límite debe estár dentro del rango de uno a tres ítems por persona, par, o equipo.
- Los límites de la cola deben mantenerse pequeños, habitualmentelos suficientemente largos para absorber la variación natural (causa-aleatoria) en el tamaño de los ítems y la duración de la tarea.
- Los cuellos de botella deben tener buffer.
- El tamaño de los buffers debe ser lo más pequeño posible, pero lo suficientemente largo para asegurar rendimiento óptimo en el cuello de botella y el mantenimiento de flujo en el sistema.
- Todos los límites de WIP pueden ajustarse empíricamente.
- Kanban es un proceso empírico.
- No debe desperdiciarse demasiado tiempo intentando determinar el límite de WIP perfecto; simplemente elija un número que es lo suficientemente cercano y progrese. Ajústelo empíricamente de ser necesario.
- Las secciones ilimitadas de niveles posteriores del proceso son posible.
- Debe tenerse cuidado de que el establecimiento de flujo de trabajo ilimitado no introduzca cuellos de botella o cause costos excesivos de transacción o coordinación cuando se hacen entregas (transferencias de lotes a niveles posteriores de proceso).
- Una vez que los límites de WIP han sido establecidos, la capacidad puede ser asignada a través de los tipos de ítems de trabajo.
- Los carriles de nado son utilizados frecuentemente para cada tipo de ítem de trabajo y un límite de WIP es establecido para cada carril.
- La asignación de capacidad requiere un análisis comparativo de demanda a través de los tipos distintos de trabajo recibido por un sistema kanban.